온라인 적응형 LLM 서빙에서 공유 추정기를 통한 사용자 간 성능 저하 공격 분석*

이도하[1], 김민기[2], 신가영[3], 허영조[4]

[1]세종대학교 (학부생) [2]서강대학교 (학부생)
[3]백석대학교 (졸업생) [4]아주대학교 (학부생)

Adversarial Robustness and Security Implications of Shared Online Estimators in LLM Serving: A vLLM Case Study

Do-Ha Lee[1], Min-Gi Kim[2], Ga-Yeong Shin[3], Young-Jo Heo[4]

[1]Sejong University (Undergraduate) [2]Sogang University (Undergraduate)
[3]Baekseok University (Graduate) [4]Ajou University (Undergraduate)

요 약

온라인 적응형 LLM 서빙은 요청 피드백으로 공유 제어 파라미터를 학습한다. 사용자 간 영향은 설계의 일부이나, 악의적 피드백의 후속 성능 영향은 별도 평가가 필요하다. 본 논문은 vLLM의 적응형 검증에서 허용된 API를 쓰는 공격자와 후속 요청의 피해자를 가정하여 이를 평가한다. 요청 종류와 갱신 여부를 교차한 실험은 공유 갱신이 후속 처리량 저하를 매개함을 지지했다. 사후 갱신이 계속되어도 관측 구간의 처리량은 사전 수준보다 낮았다. 추정기는 점진적 적응의 결과로 보기 어려운 포화 상태에 이르러, 악의적 피드백에 강건하지 않았다. 또한 피드백 수집과 공유 반영을 분리하는 대응 설계와 예비 검증의 한계를 논의한다.

I. 서론

추측 디코딩은 초안 모델의 후보 토큰을 목표 모델이 함께 검증하여 LLM 생성 속도를 높인다[1]. 초안이 자주 거절되면 생성 비용 대비 이득이 작아 검증량 선택이 성능을 좌우한다.

vLLM[2]의 적응형 검증은 채택 결과를 학습하여 다음 요청의 검증량을 조정한다. 여러 사용자의 피드백이 공유 추정기에 남는 것은 학습의 일부다.

vLLM은 프리픽스 캐시 공유[7]에 대해서는 cache_salt로 테넌트 경계를 지정하는 수단을 제공한다. 반면 적응형 검증이 학습하는 제어 상태에는 사용자별 격리나 기여량 제한이 없다. 따라서 공격자는 서버 내부에 접근하지 않고 정상 API의 입력과 요청 설정만 선택하여, 초안 채택률이 낮아지는 피드백을 공유 상태에 남길 수 있다.

본 연구는 공격자 요청 종료 후에도 다른 사용자의 처리 성능이 낮아지는지, 그 원인이 공격 요청의 실행 비용인지 공유 상태 갱신인지 평가한다.

요청 종류와 갱신 여부를 교차하여 후속 성능 저하의 크기와 갱신의 역할을 측정하고, 이를 바탕으로 승인된 갱신만 반영하는 GFC(Gated Feedback Commit) 설계를 제시한다.

II. 대상 기능과 위협 모델

2.1 공유 제어 상태가 영향을 전달하는 과정

대상은 vLLM Model Runner V2의 적응형 검증 기능이다[3]. 추정기는 이전 초안의 채택 결과로 다음 초안의 채택 가능성을 예측한다. 엔진은 이 예측으로 검증량, 즉 확인할 초안 토큰 수를 정한다. 계수와 누적 통계는 같은 모델 실행 프로세스(worker)의 요청이 공유하며, 100개 엔진 step마다 다시 학습(재적합)한다.

강건성은 불리한 피드백이나 요청 분포의 변화 속에서도 후속 처리 성능을 안정적으로 유지하는 능력이다. 본 연구는 의도적으로 불리한 피드백을 주는 한 조건에서 그 영향을 평가한다. 사용자 간

* 본 연구는 한국인터넷진흥원(KISA)이 주관하는 「차세대 보안리더 양성 프로그램(Best of the Best, BoB)」의 지원을 받아 수행된 연구임.

영향이 존재한다는 사실만으로 결함을 단정하지 않고, 그 영향이 정상적인 적응의 범위에 있는지를 상태 변화와 함께 확인한다.

이를 식 (1)로 나타낸다. s_t는 공유 상태, y_p와 c_p는 사용자 p의 피드백과 요청 문맥이다. x_q는 후속 사용자 q의 요청 특성이며, b_q는 선택된 검증량이다.

$$s_{t+1} = F(s_t, y_p(t), c_p(t))$$
$$b_q(t+1) = \pi(s_{t+1}, x_q(t+1)) \quad (1)$$

식 (1)은 사용자 p의 피드백이 공유 상태를 거쳐 사용자 q의 검증량에 이르는 경로를 나타낸다.

2.2 관련 연구와 본 연구의 차이

TurboSpec[4]과 AdaSpec[5]은 채택 가능성과 서빙 부하에 맞춰 추측 작업량을 조정하지만 악의적 사용자에게 노출된 공유 추정기의 후속 성능 영향을 다루지 않는다.

Wu 등[6]은 테스트 시점 적응에서 악의적 입력이 같은 배치의 정상 입력에 대한 예측을 바꿀 수 있음을 보였다. 본 연구는 이 문제의식을 서빙 제어 상태와 후속 요청 성능으로 확장한다.

Wang 등[10]이 적대적 접미사로 초안 채택을 무너뜨린 것과 달리, 본 연구는 그 피드백이 공유 제어 상태에 남아 공격 종료 후 다른 사용자에게 전파되는 경로를 다룬다.

2.3 공격자와 피해자

공격자는 허용된 추론 API로 피해자의 응답을 늦추려는 사용자다. 입력과 요청 설정만 선택하며 서버 내부에는 접근하지 못한다. 피해자는 같은 모델 실행 프로세스를 쓰는 다른 사용자다.

실험용 게이트웨이는 외부 식별 헤더를 제거하고 인증된 주체를 부여한다. 두 주체는 단일 worker를 공유한다. 피해자 요청은 공격자 요청이 끝나고 큐가 빈 뒤 시작하여 동시 자원 경합을 배제한다.

III. 실험 설계

3.1 비교군과 측정 순서

실험은 공격자 개입과 갱신의 효과를 나누어 비교한다. A는 낮은 초안 채택 피드백을 만드는 요청 설정을 적용한 공격자 역할의 개입군이고, P는 그 설정을 제외한 대조군이다. 요청 수, 프롬프트, 출력 길이, 샘플링과 동시성은 맞췄다. 개입 중 갱신을 허용한 S와 차단한 B를 두어 A-S, A-B, P-S, P-B 네 군을 만들었다.

차단군도 초안 생성과 목표 모델 검증을 수행하며, 피드백 누적과 재적합만 억제한다. 개입 후에는 모든 군의 갱신을 다시 허용한다. A-S와 A-B의 차이는 같은 개입에서 갱신의 효과를, P-S와 P-B의 차이는 대조 요청의 갱신 효과를 나타낸다.

각 군은 새 프로세스에서 워밍업 1,024건, 사전 128건씩 4구간, 개입 4,096건, 사후 128건씩 8구간을 실행했다. 네 군의 순서를 균형 배치한 시간 블록을 8회 반복해 32개 군을 수집했다. 기전 확인은 별도로 수행했으며 프로토콜과 판정 규칙은 수집 전에 고정했다.

3.2 실행 환경과 워크로드

실험은 AWS 서울 리전 g6e.2xlarge의 NVIDIA L40S GPU에서 수행했다. 목표 모델은 Qwen/Qwen3-4B, 초안 모델은 z-lab/Qwen3-4B-DFlash-b16[8]이며 vLLM 커밋은 4fe9e6f6e564로 고정했다.

모델 리비전은 목표 1cfa9a720891, 초안 b74e3a329c4d이다. 적응형 검증은 기본값이 꺼짐인 enable_adaptive_verification을 활성화했다. Prefix caching은 사용하지 않았다.

추측 토큰 수는 사전에 4개로 고정했다. 이는 DFlash 모델 카드의 15토큰 실행 예시와 다르며, 토큰 수의 최적값을 비교한 결과는 아니다. 피해자 워크로드는 실험용 영어 상식·산술·문장 완성 프롬프트 8종이다. 입력은 4–13토큰, 출력은 EOS를 무시한 고정 32토큰이고, 온도 0의 greedy 생성, 요청별 고정 시드와 동시성 32를 사용했다.

3.3 지표와 효과량의 의미

처리량은 구간의 총 출력 토큰을 최초 요청 시작부터 최종 응답 완료까지의 시간으로 나눈 토큰/s이다. 지연은 요청 시작부터 응답 전체 수신까지의 시간이다. 중앙값(p50)과 요청 95%가 그 값 이내에 끝나는 지연(p95)을 보고한다. 채택률은 제안된 초안 토큰 중 실제 채택된 비율이다.

군 g의 사후 처리량을 같은 블록·군의 사전 4구간 평균으로 나눈 뒤, 사후 8구간을 평균한 값을 R_g로 둔다. 1은 사전 수준, 1 미만은 처리량 감소다. 지연도 같은 방식으로 정규화한다. 개입에 따른 추가 갱신 효과는 식 (2)의 상호작용 I로 측정한다.

$$I = (R_{\mathrm{AS}} - R_{\mathrm{AB}}) - (R_{\mathrm{PS}} - R_{\mathrm{PB}}) \qquad (2)$$

첫 괄호는 A, 둘째 괄호는 P의 갱신 효과다. 두 값을 차감해 대조 요청의 적응 효과를 개입의 영향과 구분한다. 8블록을 분석 단위로 대응 블록 부트스트랩 20,000회로 신뢰구간을 구하고, 단측 정확 부호 검정으로 방향의 일관성을 확인했다.

IV. 결과와 해석

4.1 후속 요청의 성능 변화

A-S의 후속 처리량이 가장 크게 낮아졌다. 32개 군에 개입 실패나 기록 누락은 없었다. 표 1은 사전 대비 사후 평균과 8블록 범위다. 표와 그림의 범위는 관측 최소–최대이며 신뢰구간이 아니다.

표 1. 사전 대비 처리량비와 블록 범위

실험군	평균	블록 최소–최대
A-S	0.6847	[0.6793, 0.6974]
A-B	1.0018	[0.9960, 1.0100]
P-S	0.9269	[0.9138, 0.9337]
P-B	0.9962	[0.9820, 1.0046]
상호작용 I	−0.2478	[−0.2772, −0.2243]

A와 P의 갱신 효과는 각각 −0.3172와 −0.0693이다. 이를 차감한 상호작용은 −0.2478이며, 95% 신뢰구간은 [−0.2586, −0.2380]이다. 정규화 처리량비의 −24.78%p 차이로 A-S 전체 감소율과 구별된다. 8블록 모두 음수이고 p값은 0.00390625였다. 정규화 지연의 상호작용도 p50 +0.5053, p95 +0.4788로 악화했다.

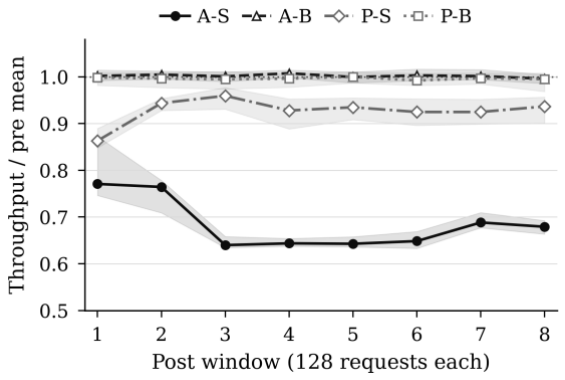


그림 1. 사후 구간별 처리량비. 선은 8블록 평균, 음영은 최소–최대이며 기준선 1은 사전 수준이다.

그림 1의 A-S는 첫 구간 0.7708에서 중간 구간 약 0.64로 낮아진 뒤 마지막에 0.6791로 일부 반등한다. 8블록의 모든 사후 구간이 기준선 아래였다. 사후 1,024건에서 사전 수준에 도달하지 않았다.

4.2 공유 갱신의 역할과 강건성 해석

갱신을 차단한 A-B는 같은 개입 뒤에도 사전 처리량에 가까웠다. 두 군은 같은 요청과 목표 검증을 수행하므로 실행 비용만으로 후속 차이를 설명하기 어렵다. P의 더 작은 갱신 효과까지 차감한 결과는 공유 갱신이 추가 저하를 매개함을 지지한다.

별도 기전 확인에서는 A의 초안 채택률이 0, P가 0.1875로 각각 갱신 허용·차단 간 같았다. 차단군의 추정기 상태는 개입 전후에 정확히 유지되었다. 반면 A의 피드백을 공유 반영하면 추정기 계수가 크게 달라졌고, 정규화 검증량의 상호작용은 −0.5163이었다. 이는 앞선 피드백이 후속 요청에서 초안을 활용하는 양을 바꾸었다는 증거다.

A-S의 8블록 모두 사후에 10회 재적합했다. 첫 위치의 계수는 사후 1구간 말 큰 양수, 2구간 말 큰 음수로 바뀌었고 마지막에도 사전 범위로 돌아오지 않았다. A-B에서는 작은 범위에 머물렀다.

vLLM 구현은 추정기 입력 특성을 ±40으로 제한한다. 사후 1·2구간 말의 첫 위치 추정기는 저장된 기울기와 절편[1]을 함께 적용하면, 이 입력

[1] Intercept[0]은 초안 첫 위치의 채택 확률 추정에 쓰이는 절편이다. 기전 확인에서 이 절편 변화의 상호작용은 −13.8508이었다. 성능 실험 A-S 8블록의 절편 범위는 사후 1구간 말 1.73×10^{4}–5.91×10^{4}, 2구간 말 -9.46×10^{5}–-8.81×10^{5}였다. 절편 자체는 처리량이나 확률이 아니다.

범위에서 예측 확률이 각각 1과 0에 가깝게 포화하는 상태였다. 따라서 사후에 관측된 상태는 다른 요청 분포에 점진적으로 적응한 결과라기보다 추정기가 포화에 이른 결과로 보는 것이 타당하다. 포화한 추정기는 입력에 따라 예측이 변하지 않으며, 후속 처리 성능도 사전 수준으로 돌아오지 않아 강건성을 유지하지 못했다. 피해자는 자신의 트래픽에 적응된 제어기가 아니라 앞선 피드백으로 포화한 제어기의 판단을 적용받으며, 유발 주체와 피해 주체가 분리된다. 다만 포화에 이른 수치적 경로와 개별 재적합의 기여는 본 연구에서 확정하지 않는다.

4.3 GFC의 설계와 예비 검증

GFC는 SafeSpec[9]의 확정 전 격리를 적응형 제어 상태에 적용해, 피드백을 인증 주체별 그림자 상태에 누적하고 이를 복제한 후보 상태에서 검증한 뒤, 통과한 경우에만 확정 상태에 반영하고 거부된 갱신은 폐기한다. 본 프로토타입은 단일 worker·단일 문맥 환경에서 주체별 분리만 구현했다. 예비 구현에서 정상 후보가 변화 한계에 걸려 거부되어(0.152 > 0.15) 임계값 보정이 필요했고, 해당 거부 경로에서만 확정 상태 불변성과 부분 커밋 부재를 확인했다.

4.4 적용 범위와 한계

결과는 적응형 검증을 켠 단일 커밋·모델 쌍·GPU·worker와 짧은 합성 워크로드에 한정된다. P는 특정 설정을 제외한 대조군으로, 정상적인 분포 변화 전반을 대표하지 않는다. 추측 디코딩을 끈 비교군도 없어, 추측 이득 상실과 비추측 방식 대비 순손실을 구분할 수 없다. 공격 4,096건 뒤 피해자 1,024건에서 저하가 이어졌다. 요청 수만으로 공격 비용과 피해 규모를 비교할 수 없으며, 같은 효과를 내는 최소 개입 규모와 관측 이후의 지속 시간은 평가하지 않았다.

GFC 예비 검증에서는 같은 입력·시드의 갱신 동결군에서도 출력이 달랐다. GPU 수치 비결정성을 배제할 수 없으며, 동일군 반복의 기준 변동(노이즈 플로어)은 미측정이다. 출력 동등성과 방어 성능은 분리 평가해야 한다.

V. 결론

요인 실험은 고정된 vLLM 구성에서 공유 갱신이 공격자 개입 후의 추가 처리량 저하를 매개함을 지지했다. 추정기는 포화 상태에 이르러 강건성을 유지하지 못했고, 관측 구간에서 사전 성능에 도달하지 않았다. GFC는 승인 게이트로 이 피드백의 반영 경계를 두는 대응 설계이며, 정상 적응 회복과 방어 효과는 추가 검증이 필요하다. 본 연구 결과는 vLLM 프로젝트에 공유하였다.

[참고문헌]

[1] Y. Leviathan, M. Kalman, and Y. Matias, “Fast Inference from Transformers via Speculative Decoding,” Proc. ICML, pp. 19274-19286, 2023.

[2] W. Kwon et al., “Efficient Memory Management for Large Language Model Serving with PagedAttention,” Proc. SOSP, 2023.

[3] The vLLM Project, “Model Runner V2: Acceptance estimation for adaptive verification,” GitHub PR #52228, 2026.

[4] X. Liu et al., “TurboSpec: Closed-loop Speculation Control System for Optimizing LLM Serving Goodput,” arXiv:2406.14066v3, 2025.

[5] K. Huang et al., “AdaSpec: Adaptive Speculative Decoding for Fast, SLO-Aware Large Language Model Serving,” Proc. SoCC, 2025.

[6] T. Wu et al., “Uncovering Adversarial Risks of Test-Time Adaptation,” Proc. ICML, pp. 37456-37495, 2023.

[7] G. Wu et al., “I Know What You Asked: Prompt Leakage via KV-Cache Sharing in Multi-Tenant LLM Serving,” Proc. NDSS, 2025.

[8] J. Chen, Y. Liang, and Z. Liu, “DFlash: Block Diffusion for Flash Speculative Decoding,” arXiv:2602.06036, 2026.

[9] K. N. Khasawneh et al., “SafeSpec: Banishing the Spectre of a Meltdown with Leakage-Free Speculation,” Proc. DAC, article 60, 2019.

[10] R. Wang et al., “Adversarial Prompts for Acceptance Collapse in Speculative Decoding,” arXiv:2607.21804, 2026.